MODEL PEMBELAJARAN DAN LAPORAN AKHIR
PROJECT-BASED LEARNING
MATA KULIAH DEEP LEARNING
KELAS B

"GENERATE WAJAH ANIME MENGGUNAKAN DEEP CONVOLUTIONAL GENERATIVE ADVERSARIAL NETWORK (DCGAN)"

DISUSUN OLEH KELOMPOK VI :

1. Reza Putri Angga (22083010006)
2. Larasati (22083010018)
3. Muhammad Azkiya Akmal (22083010084)
4. Vira Amalia Zahrani (22083010098)
5. R. Taufik Utomo Iswanindra Kusuma (22083010108)

DOSEN PENGAMPU:

Amri Muhaimin, S.Stat., M.Stat., MS (NIP. 19950723 202406 1 002)

PROGRAM STUDI SAINS DATA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN"
JAWA TIMUR

2025

DAFTAR ISI

DAFTAR ISI ii
DAFTAR TABEL iii
DAFTAR GAMBAR iv
BAB I PENDAHULUAN 1
1.1 Pendahuluan 1
BAB II METODOLOGI 2
2.1 Dataset 2
2.2 Alur Penelitian 2
2.2.1 Persiapan Dataset 2
2.2.2 Pembangunan Arsitektur Model DCGAN 3
2.2.3 Eksperimen dan *Tuning* Model *Random Search* 4
2.2.4 Analisis Stabilitas dan Pemilihan Model Terbaik 4
2.2.5 Visualisasi dan Generasi Hasil Akhir 5
BAB III HASIL DAN PEMBAHASAN 6
3.1 Instalasi dan *Import Library* 6
3.2 *Download* dan *Load* Dataset 7
3.3 Membangun Arsitektur Model 9
3.4 *Class* DCGAN & Kompilasi 13
3.5 GAN *Monitoring* 15
3.6 *Hyperparameter Tuning Random Search* 17
3.7 Analisis Stabilitas Model dan Pemilihan Model Terbaik 19
3.8 Visualisasi 21
3.9 *Generate* 10 Wajah Anime Baru 22
BAB IV KESIMPULAN 25

DAFTAR TABEL

Tabel 3. 1. Instalasi dan *Import Library*.....6
Tabel 3. 2. *Download* dan *Load* Dataset.....7
Tabel 3. 3. *Preview* Sampel Dataset.....8
Tabel 3. 4. Membangun Arsitektur Model.....9
Tabel 3. 5. Membuat Model DCGAN.....13
Tabel 3. 6. GAN *Monitoring*.....15
Tabel 3. 7. *Hyperparameter Tuning Random Search*.....17
Tabel 3. 8. Ringkasan Sederhana Hasil *Random Search*.....19
Tabel 3. 9. Pemilihan Model Terbaik.....19
Tabel 3. 10. Visualisasi Model.....21
Tabel 3. 11. *Menggenerate* Wajah Anime.....23

DAFTAR GAMBAR

Gambar 2. 1. Alur Penelitian 2
Gambar 3. 1. Sampel Dataset 9
Gambar 3. 2. Arsitektur *Generator* 12
Gambar 3. 3. Arsitektur *Discriminator* 12
Gambar 3. 4. Hasil *Random Search* 19
Gambar 3. 5. Model Terbaik 21
Gambar 3. 6. Visualisasi Model 22
Gambar 3. 7. Hasil *Generate* Wajah Anime 23

BAB I
PENDAHULUAN

1.1 Pendahuluan

Generative Adversarial Network (GAN) merupakan teknik generatif yang bekerja melalui dua jaringan yang saling berlawanan, yaitu *Generator* dan *Discriminator*. *Generator* berusaha menciptakan data baru, sedangkan *discriminator* menilai apakah data tersebut asli atau palsu. Mekanisme kompetitif antara keduanya membuat model mampu mempelajari pola visual secara mendalam. Keunggulan utama GAN terletak pada kemampuannya mempelajari distribusi data dan menghasilkan citra baru yang menyerupai data asli. Pengembangan lebih lanjut dari arsitektur ini menghasilkan berbagai varian yang lebih stabil untuk data gambar. Salah satunya adalah DCGAN yang sangat cocok digunakan pada data visual kompleks. Konsep dasar ini menjadi pondasi untuk membangun sistem generatif berbasis citra.

Deep Convolutional GAN (DCGAN) memanfaatkan *convolution* dan *transposed* convolution untuk membentuk struktur visual dengan lebih natural. Arsitektur ini dirancang agar proses pelatihan lebih stabil dan hasil gambar lebih tajam dibanding GAN biasa. DCGAN mengandalkan peran *Batch Normalization*, penggunaan aktivasi tertentu, dan desain *layer* yang lebih teratur. Tujuan utama dari pemanfaatan DCGAN dalam proyek ini adalah menghasilkan gambar baru dengan kualitas visual yang menyerupai gambar nyata. Model dilatih menggunakan sekumpulan gambar contoh sehingga mampu mengenali pola bentuk, kontur, serta gaya visual tertentu. Dengan mekanisme belajar tersebut, DCGAN dapat menciptakan citra baru dari input *noise* acak.

Tujuan dari proyek ini adalah mengembangkan model generatif yang mampu menciptakan wajah baru secara otomatis. Proses pembelajaran dilakukan menggunakan dataset berisi berbagai gambar wajah anime yang menjadi dasar bagi model dalam memahami pola visual khas anime. Kumpulan data tersebut menyediakan variasi karakter, ekspresi, serta gaya ilustrasi yang diperlukan agar model mampu membentuk citra baru dengan ciri estetika yang konsisten. Melalui pendekatan ini, proyek akan menghasilkan wajah anime baru yang dibuat sepenuhnya oleh model dari input *noise* acak. Hasil yang diperoleh bermanfaat dalam pembuatan konten kreatif seperti desain karakter atau ilustrasi digital. Selain itu, penelitian ini menunjukkan bagaimana teknologi generatif dapat mendukung proses produksi visual dengan lebih efisien dan fleksibel.

BAB II
METODOLOGI

2.1 Dataset

Dataset yang digunakan dalam proyek ini berasal dari *platform* Kaggle bernama Anime Face Dataset sejumlah 63.565 data gambar wajah anime yang dirancang khusus untuk pengembangan model generatif. Setiap gambar dalam dataset menampilkan karakter anime dengan berbagai variasi bentuk wajah, ekspresi, dan gaya ilustrasi. Keberagaman visual ini memberikan model contoh yang kaya sehingga DCGAN dapat mempelajari pola dan karakteristik estetika anime secara menyeluruh. Dataset tersebut mendukung proses pelatihan model generatif yang membutuhkan data dalam jumlah tinggi. Dengan memanfaatkan dataset dari Kaggle ini, model dapat mengembangkan pemahaman yang baik mengenai struktur dan komposisi wajah anime. Hasilnya, model mampu menghasilkan wajah baru yang tetap sesuai dengan gaya visual yang dipelajari dari dataset tersebut.

2.2 Alur Penelitian

Dalam penelitian ini terdapat beberapa tahapan utama yang saling berkaitan satu sama lain yang direpresentasikan pada diagram alur sebagai berikut.

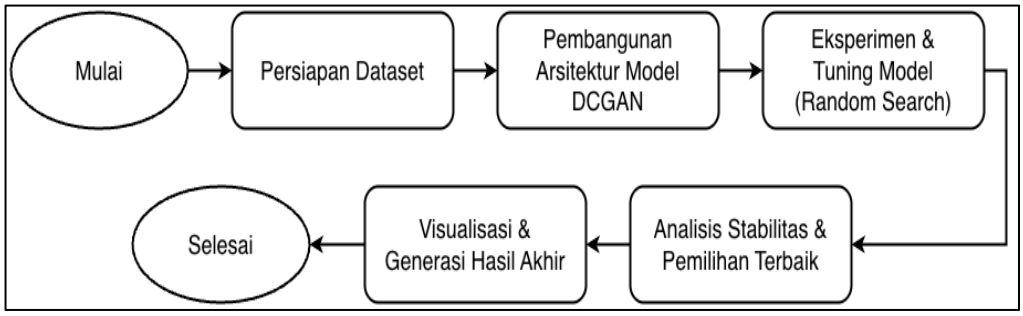

Gambar 2. 1. Alur Penelitian

Setiap tahapan yang dilakukan pada penelitian akan dijabarkan lebih lanjut sebagai berikut.

2.2.1 Persiapan Dataset

Pada tahap ini, dataset wajah anime diunduh langsung dari *platform* Kaggle menggunakan *library* kagglehub. Dataset tersebut berisi 63.565 gambar wajah anime yang menjadi dasar pembelajaran bagi model DCGAN. Gambar dimuat menggunakan *image_dataset_from_directory*, yang memungkinkan proses *loading* lebih efisien melalui

batching, *shuffling*, dan *prefetching*. Seluruh data citra kemudian dinormalisasi ke rentang [0, 1] agar selaras dengan aktivasi sigmoid pada *output generator*. Proses ini penting karena DCGAN sangat bergantung pada konsistensi skala piksel untuk stabilitas pelatihan. Dataset yang sudah diproses kemudian di *cache* untuk mempercepat proses *training*. Dengan tahap ini, data menjadi siap digunakan untuk pembangunan model generatif.

2.2.2 Pembangunan Arsitektur Model DCGAN

Langkah ini merupakan inti dari penelitian, yaitu perancangan dua model *deep learning* yang akan saling berkompetisi, yaitu *generator* dan *discriminator*. Dengan penjabaran lebih lanjut sebagai berikut.

A. Peran dan Struktur *Generator*

Generator bertugas menciptakan gambar palsu (*fake images*) yang meyakinkan dari *noise* acak. Model ini dimulai dengan menerima input berupa vektor *noise* 1D dengan dimensi 300 (*LATENT_DIM*). Vektor ini pertama-tama dilewatkan melalui *Dense layer* lalu di-*reshape* menjadi *feature map* berukuran 8×8×512. *Generator* kemudian menggunakan serangkaian lapisan *Conv2DTranspose(Transposed Convolution)*, yang berfungsi sebagai *upsampling*, untuk secara bertahap memperbesar resolusi gambar dari 8×8 menjadi 16×16, lalu 32×32, hingga mencapai *output* akhir 64×64. Aktivasi ReLU digunakan pada lapisan-lapisan tengah, dan lapisan *output* menggunakan Conv2D dengan aktivasi sigmoid untuk menghasilkan citra 64×64×3 (RGB) dengan nilai piksel di rentang [0,1].

B. Peran dan Struktur *Discriminator*

Discriminator bertugas untuk membedakan antara gambar asli dari dataset dan gambar palsu yang dibuat oleh *generator*. Model ini menerima *input* berupa gambar 64×64×3. *Discriminator* menggunakan lapisan Conv2D dan MaxPooling2D untuk melakukan *downsampling* dan mengekstrak fitur gambar secara mendalam. Setelah ekstraksi fitur, *feature map* diubah menjadi vektor 1D oleh lapisan Flatten, diikuti oleh Dense *layer*. Aktivasi LeakyReLU digunakan pada lapisan tengah untuk menjaga stabilitas pelatihan. Lapisan *output* adalah Dense *layer* tunggal dengan aktivasi sigmoid, yang menghasilkan probabilitas bahwa gambar yang dimasukkan adalah "nyata" (mendekati 1) atau "palsu" (mendekati 0).

C. Penggabungan Model (*Class* DCGAN)

Kedua model tersebut kemudian diintegrasikan dalam *class* DCGAN. Kelas ini merangkum logika pelatihan di mana *generator* dilatih untuk menipu *discriminator*,

sementara *discriminator* dilatih untuk meningkatkan akurasinya dalam membedakan. Kedua model dikompilasi menggunakan Adam *optimizer* dan fungsi *loss* Binary Crossentropy.

2.2.3 Eksperimen dan Tuning Model *Random Search*

Setelah arsitektur *generator* dan *discriminator* selesai dibangun dan digabungkan dalam *class* DCGAN, langkah selanjutnya adalah melatih model dan mencari kombinasi *hyperparameter* terbaik untuk mencapai hasil yang stabil. Dengan penjabaran lebih lanjut sebagai berikut.

A. *Random Search*

Pelatihan model GAN sangat sensitif terhadap *hyperparameter* seperti *Learning Rate* (*lr*) dan *beta_1* pada Adam *optimizer*. Oleh karena itu, penelitian ini menggunakan metode *Random Search* untuk menguji berbagai kombinasi nilai dari daftar kandidat yang telah ditentukan. Sebanyak 5 percobaan (*trial*) dijalankan. Untuk setiap *trial*, model *generator* dan *discriminator* dibangun ulang (*reset*) agar bobotnya selalu dimulai dari kondisi awal yang baru (*fresh*). Selanjutnya, kombinasi *lr* dan *beta_1* yang berbeda dipilih secara acak dari daftar kandidat untuk menginisialisasi *optimizer generator* dan *discriminator* pada *trial* tersebut.

B. Proses Pelatihan Dan Monitoring

Setiap *trial* kemudian dilatih selama 30 *epochs*. Selama proses ini, model menggunakan *callback* bernama GANMonitor. *Callback* ini memiliki dua fungsi penting:

- Monitoring Visual: Setiap 5 *epoch*, *callback* ini akan meminta *generator* membuat sampel gambar baru menggunakan *seed noise* tetap. Tampilan visual ini membantu peneliti memantau perkembangan kualitas gambar secara konsisten.
- Penyimpanan Model: Setelah mencapai *epoch* terakhir (30), model *generator* untuk *trial* tersebut akan disimpan ke dalam *file*.

Sepanjang pelatihan, nilai *loss generator* dan *discriminator* dicatat secara lengkap per-*epoch* dan disimpan sebagai *loss history*.

2.2.4 Analisis Stabilitas dan Pemilihan Model Terbaik

Langkah keempat dalam penelitian ini merupakan fase kritis di mana kinerja kelima *trial* dari *Random Search* dievaluasi secara kuantitatif, sebab dalam *Deep Generative Adversarial Network* (DGAN), model terbaik ditentukan bukan hanya dari *loss* terendah, melainkan dari stabilitas dan keseimbangan pelatihan. Proses analisis dimulai dengan

mengubah riwayat *loss generator* dan *discriminator* dari setiap *trial* ke dalam *array* numerik untuk mempermudah perhitungan. Tiga kriteria utama digunakan untuk mengevaluasi setiap model.

A. Tren Konvergensi *Loss*

Pertama, dianalisis apakah *loss* model cenderung menurun atau konvergen. Hal ini diukur dengan membandingkan rata-rata *loss* dari lima *epoch* awal dengan rata-rata *loss* dari lima *epoch* terakhir. Jika selisihnya positif, berarti *loss* cenderung menurun.

B. Stabilitas Pelatihan

Stabilitas dihitung menggunakan *Standard Deviation* (*Std Dev*) *loss* dari lima *epoch* terakhir. Nilai *std dev* yang kecil sangat diinginkan karena menunjukkan bahwa *loss* model sangat tenang dan minim fluktuasi, yang merupakan ciri dari pelatihan GAN yang stabil.

C. Keseimbangan Kompetisi

Keseimbangan diukur melalui kesenjangan (*Final Gap*) antara *loss generator* dan *discriminator*. Kesenjangan yang kecil mengindikasikan bahwa kedua model bersaing ketat dan tidak ada model yang terlalu dominan, menandakan *Nash Equilibrium* yang sehat.

Selanjutnya, metrik-metrik ini dikombinasikan untuk menghasilkan *Skor Komposit*. Jika model tidak menunjukkan tren *loss* yang menurun, model dikenakan penalti besar sebesar 1000. Skor akhir dihitung dengan menjumlahkan nilai stabilitas dan setengah dari nilai kesenjangan (*gap*). Semakin kecil skor komposit ini, semakin baik model tersebut.

2.2.5 Visualisasi dan Generasi Hasil Akhir

Alur penelitian ditutup dengan visualisasi dan hasil akhir. Model *generator* terbaik dimuat kembali dan digunakan untuk menggenerasi wajah anime baru dari *noise* acak. Hasil generasi ini menampilkan kemampuan model untuk menciptakan variasi wajah anime yang dapat dikenali, meskipun dengan beberapa artefak visual, sekaligus membuktikan keberhasilan DCGAN dalam mempelajari distribusi data.

BAB III
HASIL DAN PEMBAHASAN

Pada bagian ini akan membahas hasil serta pembahasan dari proses *generate* wajah anime menggunakan metode *Deep Convolutional Generative Adversarial Network* (DCGAN). Pembahasan difokuskan pada penjelasan kode program (*script*) yang digunakan pada setiap tahapan, mulai dari tahap persiapan data, perancangan arsitektur model, proses pelatihan (*training*), hingga evaluasi dan visualisasi hasil *generate* wajah anime.

3.1 Instalasi dan *Import Library*

Tabel 3. 1. Instalasi dan *Import Library*

Kode Script. Instalasi & *Import Library*

```
# library kagglehub
!pip install -q kagglehub

import kagglehub # library untuk download dataset dari Kaggle
import tensorflow as tf # tensorflow sebagai framework utama
from tensorflow import keras
from tensorflow.keras import layers # modul layers untuk membangun
arsitektur neural network
from tensorflow.keras.models import Sequential # sequential untuk
model layer berurutan

# jenis layer dalam DCGAN
from tensorflow.keras.layers import (
    Conv2D,              # convolution 2D untuk discriminator
    MaxPooling2D,        # max pooling
    Dense,               # fully connected layer
    Flatten,             # mengubah feature map menjadi vektor 1D
    Conv2DTranspose,     # transposed conv untuk upsampling di
generator
    Reshape,             # mengubah bentuk tensor, misalnya vektor
-> feature map
    ReLU,                # aktivasi ReLU
    LeakyReLU,           # aktivasi LeakyReLU
    BatchNormalization,  # batchnorm untuk menstabilkan training
    Dropout              # dropout untuk regularisasi
)

from tensorflow.keras.optimizers import Adam # optimizer Adam untuk
update bobot generator & discriminator
from tensorflow.keras.losses import BinaryCrossentropy # loss
function binary cross entropy untuk GAN
import matplotlib.pyplot as plt # matplotlib untuk visualisasi
gambar dan grafik loss
```

```
import numpy as np # numpy untuk operasi numerik
import pandas as pd # pandas untuk menyimpan dan menganalisis hasil
eksperimen
import os # os untuk operasi terkait sistem file
import random # random untuk hyperparameter tuning

print("Versi TensorFlow:", tf.__version__)
print("Jumlah GPU Tersedia : ",
len(tf.config.list_physical_devices('GPU')))
```

Langkah pertama yang dilakukan adalah melakukan instalasi dan *import library* yang diperlukan dalam pembangunan model DCGAN. *Library* kagglehub digunakan untuk mengunduh dataset dari Kaggle, sementara TensorFlow dan modul-modulnya digunakan untuk membangun arsitektur *generator* serta *discriminator*. Berbagai *layer* seperti `Conv2D`, `Conv2DTranspose`, `BatchNormalization`, dan `LeakyReLU` yang berfungsi membentuk dan menstabilkan jaringan. *Optimizer* Adam dan *loss* BinaryCrossentropy diperlukan untuk proses pelatihan GAN. *Library* tambahan seperti matplotlib, numpy, pandas, os, dan random digunakan untuk visualisasi, pengolahan data, serta manajemen *file*. TensorFlow dan jumlah GPU untuk memastikan lingkungan pelatihan berjalan optimal.

3.2 *Download* dan *Load* Dataset

Tabel 3. 2. *Download* dan *Load* Dataset

Kode Script. *Download* & *Load* Dataset

```
# download dataset kaggle menggunakan kagglehub
path = kagglehub.dataset_download("splcher/animefacedataset")
print("Path File Dataset:", path)

# parameter gambar yang akan digunakan sebagai ukuran input model
IMG_HEIGHT = 64
IMG_WIDTH = 64
BATCH_SIZE = 64 # batch size standar untuk dcgan
LATENT_DIM = 300 # dimensi vektor noise (latent space) yang masuk
ke generator

# load dataset dari direktori hasil download
# menggunakan image_dataset_from_directory karena lebih efisien di
memori
dataset = tf.keras.utils.image_dataset_from_directory(
    path,
    label_mode=None,        # tidak butuh label karena ini tugas gan
(unsupervised)
    image_size=(IMG_HEIGHT, IMG_WIDTH),
    batch_size=BATCH_SIZE,
    shuffle=True
```

```
)

# normalisasi piksel ke range [0, 1] karena generator menggunakan
sigmoid di output
# jika nantinya generator diganti ke tanh, normalisasi harus diubah
ke [-1, 1]
normalization_layer = layers.Rescaling(1./255)
# optimasi performa pipeline data dengan map, cache, dan prefetch
dataset = dataset.map(lambda x: normalization_layer(x))           #
terapkan normalisasi ke setiap batch
dataset = dataset.cache().prefetch(buffer_size=tf.data.AUTOTUNE) #
caching + prefetch untuk mempercepat input pipeline

print("Dataset Siap Digunakan.")
```

Langkah selanjutnya adalah mengunduh dan mempersiapkan dataset wajah anime sebelum dimasukkan ke dalam model DCGAN. Dataset diunduh otomatis menggunakan kagglehub, kemudian ditentukan parameter utama seperti ukuran gambar 64×64 piksel, *batch size* 64, serta dimensi *latent space* sebesar 300 untuk *input noise* pada *generator*. Dataset kemudian dimuat menggunakan tanpa label karena GAN bekerja secara *unsupervised*. Setelah itu, gambar dinormalisasi ke rentang [0, 1] agar sesuai dengan *output generator* yang menggunakan fungsi aktivasi sigmoid. *Pipeline* data juga dioptimalkan untuk mempercepat proses *training*. Setelah seluruh proses selesai, dataset siap digunakan untuk melatih model DCGAN.

Tabel 3. 3. *Preview* Sampel Dataset

Kode Script. *Preview* Sampel Dataset

```
# preview beberapa sampel dataset
plt.rcParams["font.family"] = "serif"

plt.figure(figsize=(8, 8))

# ambil satu batch
for batch in dataset.take(1):
    images = batch.numpy()

# tampilkan 9 gambar pertama
for i in range(9):
    plt.subplot(3, 3, i + 1)
    plt.imshow(images[i])
    plt.axis("off")

# atur judul dan jaraknya
plt.suptitle("Cuplikan Anime Face Dataset", fontsize=14, y=0.92)
plt.tight_layout(rect=[0, 0, 1, 0.9])
plt.show()
```

Ditampilkan beberapa gambar cuplikan dataset sebagai berikut.

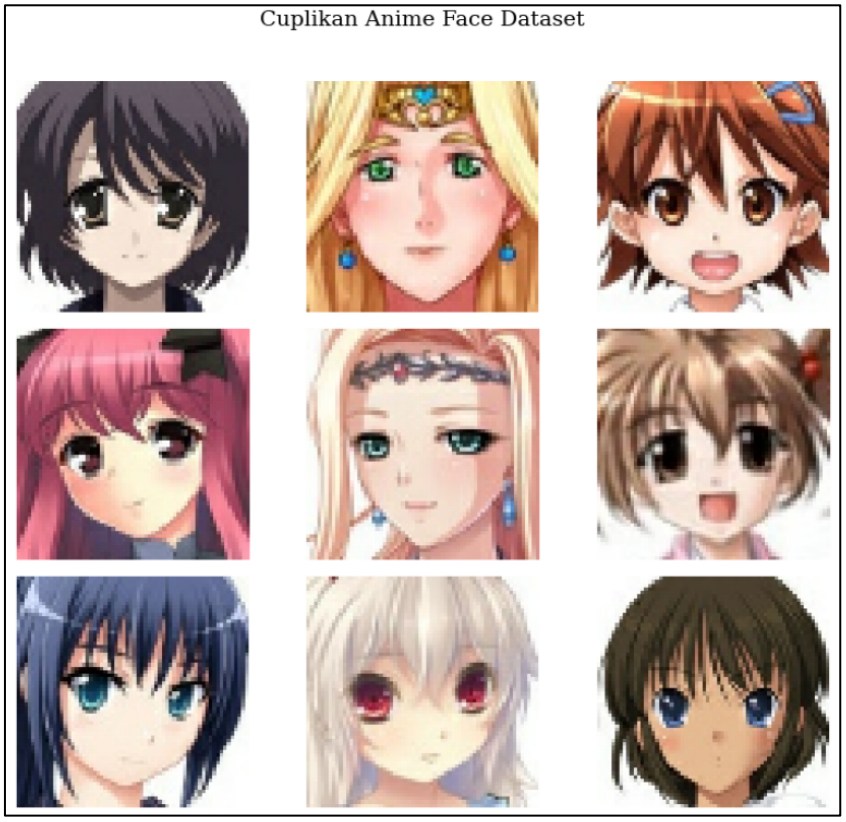

Gambar 3. 1. Sampel Dataset

Menampilkan cuplikan contoh gambar dari dataset wajah anime sebelum proses pelatihan dilakukan. Pertama, ukuran dan gaya visual plot diatur, lalu satu *batch* gambar diambil dari dataset yang telah dimuat sebelumnya. Dari *batch* tersebut, sembilan gambar pertama ditampilkan dalam format grid 3×3 tanpa menampilkan *axis* agar fokus pada gambar. Visualisasi di atas memberikan gambaran awal mengenai kualitas, variasi, dan konsistensi gambar dalam dataset yang akan digunakan untuk melatih model DCGAN.

3.3 Membangun Arsitektur Model

Tabel 3. 4. Membangun Arsitektur Model

Kode Script. Membangun Arsitektur Model

`# build generator`
`def build_generator():`
`    model = Sequential(name="Generator")`
 	
`    # input, random noise (latent vector)`
`    # dimulai dengan dense layer yang di-reshape ke 8x8x512`
`    model.add(Dense(8 * 8 * 512, input_dim=LATENT_DIM))`
`    model.add(ReLU())`

```
    # ubah vektor 1d menjadi feature map berukuran 8x8 dengan 512
channel
    model.add(Reshape((8, 8, 512)))

    # upsampling ke resolusi 16x16
    model.add(Conv2DTranspose(256, (4, 4), strides=(2, 2),
padding='same'))
    model.add(ReLU())

    # upsampling ke 32x32
    model.add(Conv2DTranspose(128, (4, 4), strides=(2, 2),
padding='same'))
    model.add(ReLU())

    # upsampling ke 64x64
    model.add(Conv2DTranspose(64, (4, 4), strides=(2, 2),
padding='same'))
    model.add(ReLU())

    # output layer, menghasilkan citra 64x64x3 (rgb)
    # aktivasi sigmoid karena data dinormalisasi ke [0, 1]
    model.add(Conv2D(3, (4, 4), padding='same',
activation='sigmoid'))
    return model

# build discriminator
def build_discriminator():
    model = Sequential(name="Discriminator")

    # input image, citra 64x64x3
    model.add(Conv2D(64, kernel_size=(3, 3), input_shape=(64, 64,
3)))
    model.add(LeakyReLU(alpha=0.2))
    # downsample ke 32x32 menggunakan max pooling
    model.add(MaxPooling2D(pool_size=(2, 2)))

    # ekstraksi fitur lanjutan dan downsample ke 16x16
    model.add(Conv2D(128, kernel_size=(3, 3)))
    model.add(LeakyReLU(alpha=0.2))
    model.add(MaxPooling2D(pool_size=(2, 2)))

    # ekstraksi fitur lebih dalam dan downsample ke 8x8
    model.add(Conv2D(256, kernel_size=(3, 3)))
    model.add(LeakyReLU(alpha=0.2))
    model.add(MaxPooling2D(pool_size=(2, 2)))

    # ubah feature map menjadi vektor 1d
    model.add(Flatten())
    # dense layer sebagai lapisan fitur tinggi sebelum output
    model.add(Dense(256))
    model.add(LeakyReLU(alpha=0.2))
```

```
    # output layer, probabilitas real vs fake (1 neuron dengan
sigmoid)
    model.add(Dense(1, activation='sigmoid'))
    return model

# build instance generator dan discriminator
generator = build_generator()
discriminator = build_discriminator()
print("Model Berhasil Dibuat.")

# menampilkan ringkasan arsitektur generator
print("Arsitektur Generator.")
generator.summary()

# menampilkan ringkasan arsitektur discriminator
print("Arsitektur Discriminator")
discriminator.summary()
```

Selanjutnya adalah membangun dua komponen utama dalam DCGAN, yaitu *generator* dan *discriminator*. Pada *generator*, model dimulai dengan menerima input berupa vektor *noise* berdimensi *latent space* yang kemudian diproses melalui *layer* Dense dan di-*reshape* menjadi *feature map* berukuran 8×8×512. Selanjutnya dilakukan proses *upsampling* bertahap menggunakan Conv2DTranspose untuk meningkatkan resolusi gambar menjadi 16×16, 32×32, hingga 64×64. Setiap tahap menggunakan aktivasi ReLU, dan *output* akhir berupa citra 64×64×3 dengan aktivasi sigmoid agar sesuai dengan data yang dinormalisasi pada rentang [0,1].

Sementara itu, *discriminator* bertugas membedakan gambar asli dan hasil generator. Model dimulai dengan menerima input gambar 64×64×3, kemudian mengekstraksi fitur menggunakan Conv2D dan menurunkan resolusi dengan MaxPooling. Proses ini dilakukan bertahap dari 64×64 → 32×32 → 16×16 → 8×8, dengan aktivasi LeakyReLU untuk menghindari masalah *dead neurons*. Setelah *feature map* di*flatten*, model dilanjutkan ke Dense *layer* dan diakhiri dengan neuron tunggal beraktivasi sigmoid untuk menghasilkan probabilitas *real* atau *fake*. Terakhir, kedua model dibangun menjadi *instance*, lalu ditampilkan ringkasan arsitekturnya sebagai verifikasi bahwa *generator* dan *discriminator* berhasil dibuat dengan benar. Dengan *summary generator* dan *dicriminator* sebagai berikut.

Model: "Generator"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 32768)	9,863,168
re_lu (ReLU)	(None, 32768)	0
reshape (Reshape)	(None, 8, 8, 512)	0
conv2d_transpose (Conv2DTranspose)	(None, 16, 16, 256)	2,097,408
re_lu_1 (ReLU)	(None, 16, 16, 256)	0
conv2d_transpose_1 (Conv2DTranspose)	(None, 32, 32, 128)	524,416
re_lu_2 (ReLU)	(None, 32, 32, 128)	0
conv2d_transpose_2 (Conv2DTranspose)	(None, 64, 64, 64)	131,136
re_lu_3 (ReLU)	(None, 64, 64, 64)	0
conv2d (Conv2D)	(None, 64, 64, 3)	3,075

Total params: 12,619,203 (48.14 MB)
Trainable params: 12,619,203 (48.14 MB)
Non-trainable params: 0 (0.00 B)

Gambar 3. 2. Arsitektur *Generator*

Model: "Discriminator"

Layer (type)	Output Shape	Param #
conv2d_1 (Conv2D)	(None, 62, 62, 64)	1,792
leaky_re_lu (LeakyReLU)	(None, 62, 62, 64)	0
max_pooling2d (MaxPooling2D)	(None, 31, 31, 64)	0
conv2d_2 (Conv2D)	(None, 29, 29, 128)	73,856
leaky_re_lu_1 (LeakyReLU)	(None, 29, 29, 128)	0
max_pooling2d_1 (MaxPooling2D)	(None, 14, 14, 128)	0
conv2d_3 (Conv2D)	(None, 12, 12, 256)	295,168
leaky_re_lu_2 (LeakyReLU)	(None, 12, 12, 256)	0
max_pooling2d_2 (MaxPooling2D)	(None, 6, 6, 256)	0
flatten (Flatten)	(None, 9216)	0
dense_1 (Dense)	(None, 256)	2,359,552
leaky_re_lu_3 (LeakyReLU)	(None, 256)	0
dense_2 (Dense)	(None, 1)	257

Total params: 2,730,625 (10.42 MB)
Trainable params: 2,730,625 (10.42 MB)
Non-trainable params: 0 (0.00 B)

Gambar 3. 3. Arsitektur *Discriminator*

3.4 *Class* DCGAN & Kompilasi

Tabel 3. 5. Membuat Model DCGAN

Kode Script. Class DCGAN & Kompilasi

```
# class dcgan
class DCGAN(keras.Model):
    def __init__(self, generator, discriminator, latent_dim):
        # memanggil konstruktor kelas induk (keras.model)
        super().__init__()
        # menyimpan referensi ke generator dan discriminator
        self.generator = generator
        self.discriminator = discriminator
        # menyimpan dimensi vektor noise (latent space)
        self.latent_dim = latent_dim

        # trackers untuk menyimpan nilai rata-rata loss generator
dan discriminator
        self.g_loss_metric = keras.metrics.Mean(name='g_loss')
        self.d_loss_metric = keras.metrics.Mean(name='d_loss')

    @property
    def metrics(self):
        # daftar metric yang akan di-reset otomatis setiap epoch
oleh keras
        return [self.g_loss_metric, self.d_loss_metric]

    def compile(self, g_optimizer, d_optimizer, loss_fn):
        # memanggil compile bawaan keras.model
        super(DCGAN, self).compile()
        # menyimpan optimizer untuk generator dan discriminator
        self.g_optimizer = g_optimizer
        self.d_optimizer = d_optimizer
        # menyimpan fungsi loss yang digunakan (binary
crossentropy)
        self.loss_fn = loss_fn

    def train_step(self, real_images):
        # train discriminator
        # mengambil ukuran batch dari tensor real_images
        batch_size = tf.shape(real_images)[0]
        # membuat noise acak sebagai input generator
        random_noise = tf.random.normal(shape=(batch_size,
self.latent_dim))

        with tf.GradientTape() as tape:
            # generate fake images dari generator
            fake_images = self.generator(random_noise,
training=True)

            # prediksi discriminator pada gambar asli dan palsu
            pred_real = self.discriminator(real_images,
```

```
training=True)
            pred_fake = self.discriminator(fake_images,
training=True)

            # label: real = 1, fake = 0 (dengan smoothing pada
label real)
            real_labels = tf.ones((batch_size, 1))
            # label smoothing ringan agar discriminator tidak
terlalu percaya diri
            real_labels += 0.05 *
tf.random.uniform(tf.shape(real_labels))
            fake_labels = tf.zeros((batch_size, 1))

            # hitung loss untuk real dan fake
            d_loss_real = self.loss_fn(real_labels, pred_real)
            d_loss_fake = self.loss_fn(fake_labels, pred_fake)
            # loss total discriminator adalah rata-rata keduanya
            d_loss = (d_loss_real + d_loss_fake) / 2

        # update bobot discriminator berdasarkan gradien
        grads = tape.gradient(d_loss,
self.discriminator.trainable_variables)
        self.d_optimizer.apply_gradients(zip(grads,
self.discriminator.trainable_variables))

        # train generator
        with tf.GradientTape() as tape:
            # generate batch baru fake images dari noise
            random_noise = tf.random.normal(shape=(batch_size,
self.latent_dim))
            fake_images = self.generator(random_noise,
training=True)

            # discriminator menilai fake images ini
            pred_fake = self.discriminator(fake_images,
training=True)
            # generator ingin discriminator menganggap fake sebagai
real (label = 1)
            misleading_labels = tf.ones((batch_size, 1))

            # loss generator: seberapa baik ia bisa menipu
discriminator
            g_loss = self.loss_fn(misleading_labels, pred_fake)

        # update bobot generator berdasarkan gradien
        grads = tape.gradient(g_loss,
self.generator.trainable_variables)
        self.g_optimizer.apply_gradients(zip(grads,
self.generator.trainable_variables))

        # update metric loss untuk dipantau saat training
        self.d_loss_metric.update_state(d_loss)
```

```
        self.g_loss_metric.update_state(g_loss)

        # mengembalikan dictionary berisi nilai loss yang akan
ditampilkan di log
        return {
            "d_loss": self.d_loss_metric.result(),
            "g_loss": self.g_loss_metric.result(),
        }

# inisialisasi optimizers
# learning rate biasanya kecil untuk gan agar training lebih stabil
lr = 0.0002
beta_1 = 0.5

# optimizer adam untuk generator dan discriminator
g_optimizer = Adam(learning_rate=lr, beta_1=beta_1)
d_optimizer = Adam(learning_rate=lr, beta_1=beta_1)
# fungsi loss binary crossentropy untuk membedakan real vs fake
loss_fn = BinaryCrossentropy()

# buat model dcgan dengan generator, discriminator, dan latent_dim
yang sudah didefinisikan
dcgan = DCGAN(generator, discriminator, LATENT_DIM)
# kompilasi model dengan optimizer dan loss yang sudah disiapkan
dcgan.compile(g_optimizer, d_optimizer, loss_fn)
```

Langkah selanjutnya membangun kelas DCGAN berbasis yang menggabungkan *generator* dan *discriminator* ke dalam satu model terstruktur. Pada konstruktor, kelas menyimpan referensi kedua model beserta dimensi *latent space* serta menyiapkan metrik untuk mencatat rata-rata *loss generator* dan *discriminator*. Metode `compile()` digunakan untuk menyimpan *optimizer* dan fungsi *loss* yang akan digunakan selama pelatihan. Fungsi inti `train_step()` mengatur proses *training* setiap *batch*, dimulai dengan melatih *discriminator* menggunakan gambar asli dan gambar palsu hasil *generator*, lengkap dengan *label smoothing* untuk meningkatkan stabilitas. Setelah bobot *discriminator* diperbarui, *generator* dilatih agar mampu menghasilkan gambar palsu yang dianggap *real* oleh *discriminator*. Di bagian akhir, model DCGAN dikompilasi dengan *optimizer* Adam *learning rate* kecil dan fungsi *loss* Binary Crossentropy yang umum digunakan dalam GAN.

3.5 GAN *Monitoring*

Tabel 3. 6. GAN *Monitoring*

Kode Script. GAN Monitoring
`# callback untuk memantau proses training gan dan menyimpan hasil generator`

```
class GANMonitor(keras.callbacks.Callback):
    def __init__(self, num_img=5, latent_dim=LATENT_DIM,
prefix=''):
        # jumlah gambar yang akan digenerate untuk preview
        self.num_img = num_img
        # dimensi vektor noise yang digunakan generator
        self.latent_dim = latent_dim
        # prefix untuk nama file model yang disimpan (misalnya
berisi nama trial)
        self.prefix = prefix
        # seed noise tetap agar gambar preview konsisten antar
epoch
        self.seed = tf.random.normal([num_img, latent_dim])

    def on_epoch_end(self, epoch, logs=None):
        # jika sudah mencapai epoch terakhir, simpan model
generator ke file
        if (epoch + 1) == EPOCHS:

self.model.generator.save(f"Generator_{self.prefix}.h5")

        # setiap 5 epoch, generate dan tampilkan sample gambar dari
generator
        if (epoch + 1) % 5 == 0:
            generated_images = self.model.generator(self.seed)
            generated_images = generated_images.numpy()

            # membuat figure untuk menampilkan beberapa gambar
sekaligus
            fig = plt.figure(figsize=(15, 5))
            for i in range(self.num_img):
                plt.subplot(1, self.num_img, i + 1)
                img = generated_images[i]
                plt.imshow(img)      # menampilkan gambar hasil
generator
                plt.axis('off')
            plt.suptitle(f"EXP: {self.prefix} - Epoch {epoch + 1}")
            plt.show()
```

Membuat kelas *callback* bernama `GANMonitor` yang digunakan untuk memantau proses pelatihan DCGAN secara otomatis. *Callback* ini menghasilkan beberapa gambar contoh dari *generator* pada interval tertentu untuk melihat perkembangan kualitas hasil selama training. Kelas ini menyimpan jumlah gambar *preview*, dimensi *latent space*, serta *prefix* sebagai penanda nama *file*. Selain itu, *seed noise* dibuat tetap agar visualisasi antar *epoch* konsisten. Pada akhir setiap *epoch*, jika mencapai *epoch* terakhir maka model *generator* disimpan ke dalam *file* .h5. Kemudian, setiap 5 *epoch*, *callback* menghasilkan gambar dari

generator menggunakan *seed* tetap tersebut dan menampilkannya dalam bentuk *grid*, sehingga peneliti dapat memantau apakah kualitas gambar semakin membaik.

3.6 Hyperparameter Tuning Random Search

Tabel 3. 7. *Hyperparameter Tuning Random Search*

Kode Script. *Hyperparameter Tuning Random Search*

```
# setup daftar kandidat hyperparameter yang akan diuji
lr_choices = [0.0001, 0.0002, 0.0003, 0.0004, 0.00005]   # daftar
kandidat learning rate
beta_1_choices = [0.4, 0.5, 0.6, 0.7, 0.8, 0.9]          # daftar
kandidat beta_1 untuk optimizer adam

# tentukan batasan percobaan
NUM_TRIALS = 5  # jumlah percobaan acak yang akan dijalankan
EPOCHS = 30     # jumlah epoch yang digunakan untuk setiap
percobaan

# list untuk menyimpan hasil tiap trial
results = []
print(f"Mulai Random Search {NUM_TRIALS} Trials...")

# loop untuk menjalankan beberapa trial random search
for trial in range(NUM_TRIALS):

    # random sampling
    # pilih satu kombinasi lr dan beta_1 secara acak dari daftar
    lr = random.choice(lr_choices)
    beta_1 = random.choice(beta_1_choices)

    # buat nama unik untuk setiap percobaan berdasarkan nomor trial
dan kombinasi hyperparameter
    run_name = f"Trial{trial+1}_lr{lr}_beta{beta_1}"

    print(f"\n Menjalankan Eksperimen {trial+1}/{NUM_TRIALS}:
{run_name} ")

    # 1. reset model (sangat penting)
    # build ulang generator dan discriminator agar bobot mulai dari
kondisi awal (fresh)
    clean_generator = build_generator()
    clean_discriminator = build_discriminator()

    # 2. inisialisasi optimizer dengan kombinasi hyperparameter
untuk trial ini
    g_optimizer = Adam(learning_rate=lr, beta_1=beta_1)
    d_optimizer = Adam(learning_rate=lr, beta_1=beta_1)
    loss_fn = BinaryCrossentropy()
```

```
    # 3. compile dcgan dengan optimizer dan loss yang sudah
ditentukan
    dcgan = DCGAN(clean_generator, clean_discriminator, LATENT_DIM)
    dcgan.compile(g_optimizer, d_optimizer, loss_fn)

    # 4. training dcgan dengan dataset yang sudah disiapkan
    # run_name digunakan sebagai prefix di callback agar file
model/gambar tersimpan terpisah per trial
    history = dcgan.fit(
        dataset,
        epochs=EPOCHS,
        callbacks=[GANMonitor(num_img=5, latent_dim=LATENT_DIM,
prefix=run_name)],
        verbose=1  # ubah ke 0 jika ingin log training lebih
ringkas
    )

    # 5. simpan hasil training untuk trial ini
    # menyimpan nilai loss terakhir dan history penuh untuk
analisis stabilitas
    results.append({
        'run_name': run_name,
        'lr': lr,
        'beta_1': beta_1,
        'final_g_loss': history.history['g_loss'][-1],
        'final_d_loss': history.history['d_loss'][-1],
        'g_loss_history': history.history['g_loss'],  # simpan list
lengkap loss generator per epoch
        'd_loss_history': history.history['d_loss']   # simpan list
lengkap loss discriminator per epoch
    })

# --- hasil akhir ---
print("\n Random Search Selesai")
```

Menerapkan teknik *Random Search* untuk mencari kombinasi *hyperparameter* terbaik dalam pelatihan DCGAN, khususnya *learning rate* dan nilai *beta_1* pada *optimizer* Adam. Pada setiap *trial*, kombinasi *hyperparameter* dipilih secara acak, kemudian *generator* dan *discriminator* di-*reset* untuk memastikan model mulai dari kondisi awal. Selanjutnya dilakukan proses kompilasi dan pelatihan DCGAN selama 30 *epoch* dengan *callback* `GANMonitor` untuk menyimpan hasil gambar setiap *trial*. Setelah *training* selesai, nilai akhir *loss generator* dan *discriminator*, serta riwayat *loss* disimpan ke dalam *list results*. Hasil ini nantinya digunakan untuk mengevaluasi stabilitas dan memilih kombinasi *hyperparameter* terbaik. Kemudian terdapat ringkasan hasil *random search* yang dilakukan dengan kode *script* sebagai berikut.

Tabel 3. 8. Ringkasan Sederhana Hasil *Random Search*

Kode Script. Ringkasan Sederhana Hasil *Random Search*

```
# buat ringkasan sederhana hasil random search
summary_data = []
for res in results:
    summary_data.append({
        'run_name': res['run_name'],          # nama trial
(berisi info lr dan beta_1)
        'lr': res['lr'],                      # learning rate
yang dipakai di trial ini
        'beta_1': res['beta_1'],              # nilai beta_1
adam di trial ini
        'final_g_loss': res['final_g_loss'],  # nilai loss
generator di epoch terakhir
        'final_d_loss': res['final_d_loss']   # nilai loss
discriminator di epoch terakhir
    })

# konversi ringkasan ke dataframe agar mudah dibaca dan
dianalisis
df_results = pd.DataFrame(summary_data)
print(df_results)
```

Dengan hasil sebagai berikut.

	run_name	lr	beta_1	final_g_loss	final_d_loss
0	Trial1_lr0.0003_beta0.7	0.0003	0.7	2.725470	0.243234
1	Trial2_lr0.0003_beta0.4	0.0003	0.4	3.301110	0.025507
2	Trial3_lr0.0001_beta0.9	0.0001	0.9	269.739227	3224.771973
3	Trial4_lr0.0001_beta0.7	0.0001	0.7	1.983893	0.312851
4	Trial5_lr0.0001_beta0.7	0.0001	0.7	2.061505	0.303084

Gambar 3. 4. Hasil *Random Search*

3.7 Analisis Stabilitas Model dan Pemilihan Model Terbaik

Tabel 3. 9. Pemilihan Model Terbaik

Kode Script. Pemilihan Model Terbaik

```
print("\n Analisis Stabilitas Model ")

# inisialisasi nilai skor terbaik dengan tak hingga (semakin kecil
semakin bagus)
best_score = float('inf')
# menyimpan nama model terbaik berdasarkan skor
best_model_name = None
# list untuk menyimpan log analisis tiap model
```

```
analysis_log = []

# loop untuk setiap hasil trial yang tersimpan di results
for res in results:
    # konversi history loss generator dan discriminator ke numpy
array
    g_hist = np.array(res['g_loss_history'])
    d_hist = np.array(res['d_loss_history'])

    # 1. cek tren menurun (slope)
    # bandingkan rata-rata 5 epoch awal vs 5 epoch akhir
    # jika (awal - akhir) > 0, berarti loss cenderung menurun
(good)
    g_decrease = np.mean(g_hist[:5]) - np.mean(g_hist[-5:])
    d_decrease = np.mean(d_hist[:5]) - np.mean(d_hist[-5:])

    # true jika keduanya (g dan d) sama-sama mengalami penurunan
    is_decreasing = (g_decrease > 0) and (d_decrease > 0)

    # 2. cek stabilitas (standard deviation di 5 epoch terakhir)
    # semakin kecil std dev, semakin stabil (garis loss lebih
tenang di akhir)
    g_stability = np.std(g_hist[-5:])
    d_stability = np.std(d_hist[-5:])

    # 3. cek keseimbangan (gap antara loss g dan d)
    # kita ingin g dan d bersaing ketat, jadi gap loss-nya jangan
terlalu jauh
    final_gap = abs(np.mean(g_hist[-5:]) - np.mean(d_hist[-5:]))

    # skoring
    # membuat skor komposit (semakin kecil semakin baik)
    # bobot bisa disesuaikan, di sini stabilitas lebih diutamakan
    # jika tidak decreasing, diberi penalti besar (+1000)
    penalty = 0 if is_decreasing else 1000

    # score = (stabilitas g + stabilitas d) + (gap g vs d * 0.5) +
penalti
    score = (g_stability + d_stability) + (final_gap * 0.5) +
penalty

    # simpan hasil analisis untuk model ini ke dalam log
    analysis_log.append({
        'name': res['run_name'],
        'decreasing': is_decreasing,
        'stability_score': (g_stability + d_stability),
        'gap': final_gap,
        'total_score': score
    })

    # tampilkan ringkasan analisis untuk setiap model
    print(
```

```
        f"model: {res['run_name']} | "
        f"decreasing: {is_decreasing} | "
        f"stability (std): {g_stability + d_stability:.4f} | "
        f"final gap: {final_gap:.4f}")

    # update model terbaik jika skor sekarang lebih kecil dari
best_score sebelumnya
    if score < best_score:
        best_score = score
        best_model_name = res['run_name']

# keputusan
print(f"\n Rekomendasi Model Terbaik: {best_model_name}")
print("Alasan: Memiliki kombinasi stabilitas terbaik dan tren loss
yang konvergen.")
```

Dengan hasil sebagai berikut.

```
 Analisis Stabilitas Model
model: Trial1_lr0.0003_beta0.7 | decreasing: False | stability (std): 0.1032 | final gap: 2.5298
model: Trial2_lr0.0003_beta0.4 | decreasing: False | stability (std): 0.1121 | final gap: 3.2628
model: Trial3_lr0.0001_beta0.9 | decreasing: False | stability (std): 9287.9144 | final gap: 10936.0055
model: Trial4_lr0.0001_beta0.7 | decreasing: False | stability (std): 0.0496 | final gap: 1.6090
model: Trial5_lr0.0001_beta0.7 | decreasing: False | stability (std): 0.0330 | final gap: 1.7174

 Rekomendasi Model Terbaik: Trial4_lr0.0001_beta0.7
Alasan: Memiliki kombinasi stabilitas terbaik dan tren loss yang konvergen.
```

Gambar 3. 5. Model Terbaik

Mencari model DCGAN terbaik dari seluruh percobaan *random search*. Setiap *trial* dianalisis berdasarkan tiga aspek utama, yaitu tren penurunan *loss*, stabilitas, dan keseimbangan antara *generator* dan *discriminator*. Pertama, model mengecek apakah *loss generator* dan *discriminator* menunjukkan tren menurun dengan membandingkan rata-rata lima *epoch* awal dan lima *epoch* akhir. Kedua, stabilitas dihitung menggunakan standar deviasi dari lima *epoch* terakhir, di mana nilai lebih kecil berarti model lebih stabil. Ketiga, keseimbangan dinilai dari selisih antara rata-rata *loss generator* dan *discriminator*, selisih kecil menunjukkan kompetisi yang seimbang.

Ketiga komponen ini digabung menjadi sebuah skor, di mana skor rendah berarti model lebih baik. Jika sebuah model tidak memiliki tren penurunan, maka diberi penalti besar agar tidak terpilih. Setelah seluruh model dievaluasi, sistem memilih model dengan skor paling kecil sebagai model DCGAN terbaik karena dianggap paling stabil, paling konvergen, dan paling seimbang. Dihasilkan model terbaik **Trial4_lr0.0001_beta0.7**.

3.8 Visualisasi

Tabel 3. 10. Visualisasi Model

```
Kode Script. Visualisasi
```

```
# visualisasi grafik loss model terbaik
# cari data model terbaik berdasarkan nama run
best_run_data = next(item for item in results if item["run_name"]
== best_model_name)

plt.figure(figsize=(10, 5))
plt.plot(best_run_data['g_loss_history'], label='generator loss')
plt.plot(best_run_data['d_loss_history'], label='discriminator
loss')
plt.title(f"loss history: {best_model_name} (best model)")
plt.xlabel("epoch")
plt.ylabel("loss")
plt.legend()
plt.grid(True)
plt.show()
```

Dengan hasil visualisasi sebagai berikut.

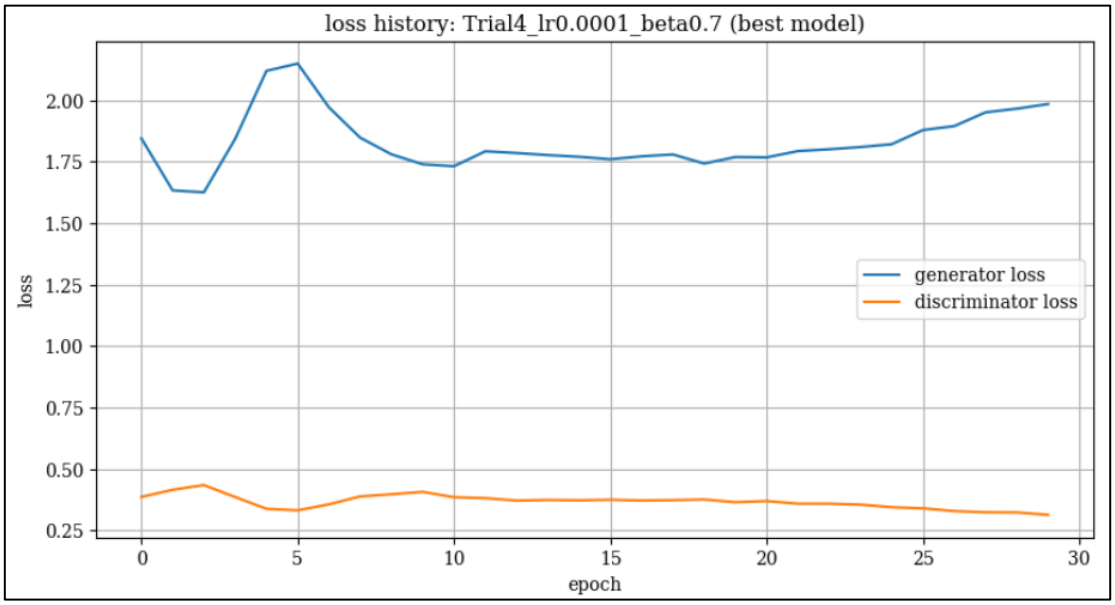

Gambar 3. 6. Visualisasi Model

Visualisasi diatas menampilkan grafik riwayat *loss* dari model terbaik yang telah dipilih berdasarkan analisis stabilitas sebelumnya. Grafik ini memplot nilai *generator loss* dan *discriminator loss* pada setiap *epoch* untuk memudahkan pengamatan pola pelatihan. Tampilan kedua kurva tersebut membantu melihat apakah model menunjukkan kecenderungan belajar yang konsisten, stabil, dan seimbang selama proses pelatihan. Grafik ini juga menegaskan alasan terpilihnya model terbaik, yaitu karena memiliki tren *loss* yang konvergen dan perbedaan yang tidak terlalu besar antara *generator* dan *discriminator*.

3.9 *Generate* 10 Wajah Anime Baru

Tabel 3. 11. *Menggenerate* Wajah Anime

Kode Script. Menggenerate Wajah Anime

```
# generate dan tampilkan 10 wajah anime baru dari model terbaik
# load kembali generator terbaik dari file yang sudah disimpan
best_generator_path = f"Generator_{best_model_name}.h5"
best_generator = tf.keras.models.load_model(best_generator_path)

# buat noise acak sebagai input generator
num_samples = 10                          # jumlah gambar yang ingin
ditampilkan
z = tf.random.normal([num_samples, LATENT_DIM])

# generate gambar dari noise
generated_images = best_generator(z)
generated_images = generated_images.numpy()

# jika output generator di [0, 1], tidak perlu transformasi
tambahan
# jika kamu pakai tanh dan [-1, 1], tambahkan baris:
# generated_images = (generated_images + 1.0) * 0.5

# tampilkan dalam grid 2x5
plt.figure(figsize=(15, 6))
for i in range(num_samples):
    plt.subplot(2, 5, i + 1)
    img = np.clip(generated_images[i], 0.0, 1.0)  # memastikan
nilai tetap di range valid
    plt.imshow(img)
    plt.axis("off")

plt.suptitle(f"Hasil Generate Wajah Anime: {best_model_name}",
fontsize=14)
plt.show()
```

Dengan hasil visualisasi sebagai berikut.

Gambar 3. 7. Hasil *Generate* Wajah Anime

Gambar 3.7 menampilkan proses dan hasil generasi 10 wajah anime baru menggunakan model *generator* terbaik yang sebelumnya telah dipilih melalui analisis stabilitas. *generator* tersebut dimuat ulang dari *file* model yang disimpan, kemudian diberi masukan berupa vektor noise acak berukuran sesuai *latent dimension*. *Noise* tersebut diproses oleh *generator* untuk menghasilkan citra wajah anime baru yang kemudian ditampilkan dalam grid 2×5. Proses ini menunjukkan kemampuan model dalam membentuk pola visual baru yang menyerupai dataset latih, sekaligus mengilustrasikan kualitas dan konsistensi hasil generasi model terbaik.

BAB IV
KESIMPULAN

Penelitian ini berhasil mengembangkan model *Deep Convolutional Generative Adversarial Network* (DCGAN) yang mampu menghasilkan citra wajah anime baru, memenuhi tujuan proyek dalam pembuatan model generatif visual. Keberhasilan ini didukung oleh proses Eksperimen *Random Search* yang menguji lima kombinasi *hyperparameter* untuk mencari konfigurasi pelatihan yang paling stabil. Melalui analisis kuantitatif, model **Trial4_lr0.0001_beta0.7** ditetapkan sebagai model terbaik. Model ini dipilih karena menunjukkan kombinasi stabilitas terbaik dengan nilai standar deviasi (*std*) terendah, yaitu hanya 0.0496, di antara semua *trial* yang berhasil. Hal ini membuktikan bahwa konfigurasi *hyperparameter* tersebut menghasilkan *Nash Equilibrium* yang paling baik antara *generator* dan *discriminator*. Dengan demikian, fase *tuning* model berhasil mengidentifikasi parameter yang optimal untuk menjamin konvergensi yang stabil selama 30 *epoch*.

Visualisasi *loss history* model terbaik ini mengonfirmasi stabilitas pelatihan, di mana kedua garis *loss* telah menetap pada nilai yang rendah dan minim fluktuasi setelah *epoch* awal. *generator* terbaik kemudian berhasil menghasilkan 10 sampel wajah anime baru dari *noise* acak, menampilkan keragaman dalam warna rambut dan fitur wajah. Model terbukti efektif telah mempelajari dan mereplikasi pola struktural wajah dan gaya estetika visual anime. Keberhasilan ini membuktikan potensi DCGAN dalam mendukung proses kreatif seperti desain karakter dan ilustrasi digital. Akhirnya, penelitian ini mencapai tujuannya dengan menghasilkan model generatif yang stabil dan mampu menciptakan citra baru yang menyerupai data asli.